

# Lab02

Mariana Zamith Feltrin

## Exercício 1

Para calcular as estatísticas suficientes para a determinação do percentual de voos atrasados na chegada (`ARRIVAL_DELAY > 10`) por dia e companhia aérea, precisamos do número de voos atrasados e o número total de voos no dia e companhia desejados.

## Exercício 2

```
library(dplyr)
```

Anexando pacote: 'dplyr'

Os seguintes objetos são mascarados por 'package:stats':

```
filter, lag
```

Os seguintes objetos são mascarados por 'package:base':

```
intersect, setdiff, setequal, union
```

```
library(readr)

getStats <- function(input, pos) {
  input %>%
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%
    filter(!is.na(MONTH), !is.na(DAY), !is.na(ARRIVAL_DELAY)) %>%
    group_by(MONTH, DAY, AIRLINE) %>%
```

```

    summarise(
      n_total = n(),
      n_atrasados = sum(ARRIVAL_DELAY > 10),
      .groups = "drop"
    )
}

```

# .groups = "drop", ao salvar de volta, não guarda o resultado no agrupamento utilizado

### Exercício 3

```

#colunas que vão ser usadas
mycols <- cols_only(
  MONTH = col_integer(),
  DAY = col_integer(),
  AIRLINE = col_character(),
  ARRIVAL_DELAY = col_double()
)

in2 <- read_csv_chunked(
  "flights.csv.zip",
  callback = DataFrameCallback$new(getStats),
  chunk_size = 100000,
  col_types = mycols
)

in2

```

```

# A tibble: 1,478 x 5
  MONTH DAY AIRLINE n_total n_atrasados
  <int> <int> <chr>      <int>      <int>
1     1     1   1 AA         1379         514
2     1     1   1 DL         1558         132
3     1     1   1 UA         1269         367
4     1     1   1 US         1028         201
5     1     2   2 AA         1508         649
6     1     2   2 DL         2261         406
7     1     2   2 UA         1411         493
8     1     2   2 US         1174         229

```

```

  9      1      3 AA      1425      767
10      1      3 DL      2021      702
# i 1,468 more rows

```

## Exercício 4

```

computeStats <- function(input) {
  input %>%
    group_by(MONTH, DAY, AIRLINE) %>%
    summarise(
      n_total = sum(n_total),
      n_atrasados = sum(n_atrasados),
      .groups = "drop"
    ) %>%
    mutate(
      Cia = AIRLINE,
      Data = as.Date(
        paste(2015, MONTH, DAY, sep = "-")
      ),
      Perc = n_atrasados / n_total
    ) %>%
    select(Cia, Data, Perc)
}

dados_finais <- computeStats(in2)
dados_finais

```

```

# A tibble: 1,276 x 3
   Cia    Data      Perc
  <chr> <date>    <dbl>
1 AA    2015-01-01 0.373
2 DL    2015-01-01 0.0847
3 UA    2015-01-01 0.289
4 US    2015-01-01 0.196
5 AA    2015-01-02 0.430
6 DL    2015-01-02 0.180
7 UA    2015-01-02 0.349
8 US    2015-01-02 0.195
9 AA    2015-01-03 0.538
10 DL   2015-01-03 0.347
# i 1,266 more rows

```

## Exercício 5

```
library(ggplot2)
library(ggcal)


pal <- scale_fill_gradient(low = "#4575b4", high = "#d73027")

baseCalendario <- function(stats, cia) {
  df_cia <- stats %>% filter(Cia == cia)
  ggcal(df_cia$Data, df_cia$Perc)
}

cAA <- baseCalendario(dados_finais, "AA") + pal + ggtitle("Percentual de Atraso em 2015 - Am
cDL <- baseCalendario(dados_finais, "DL") + pal + ggtitle("Percentual de Atraso em 2015 - De
cUA <- baseCalendario(dados_finais, "UA") + pal + ggtitle("Percentual de Atraso em 2015 - Un
cUS <- baseCalendario(dados_finais, "US") + pal + ggtitle("Percentual de Atraso em 2015 - US


cAA
```

### Percentual de Atraso em 2015 – American Airlines (AA)




cDL

## Percentual de Atraso em 2015 – Delta Air Lines (DL)




cUA

## Percentual de Atraso em 2015 – United Airlines (UA)



## Percentual de Atraso em 2015 – US Airways (US)



```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-08-24 16:09:25 -03"
```